



T.C.
KIRŞEHİR AHI EVRAN ÜNİVERSİTESİ
MÜHENDİSLİK -MİMARLIK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ

YAPAY ZEKÂ TARAFINDAN ÜRETİLEN VİDEOLARI (DEEPFAKE) TESPİT EDEN UYGULAMA

MERVE EDİZ

LİSANS TEZİ

DANIŞMAN
Dr.Öğr.Üyesi Volkan Güneş

KIRŞEHİR / 2025-2026 AKADEMİK YILI

İÇİNDEKİLER

Sayfa No

İÇİNDEKİLER.....	1
ŞEKİL LİSTESİ.....	2
TABLO LİSTESİ.....	3
SİMGE VE KISALTMA LİSTESİ.....	4
ÖZET.....	5
1. GİRİŞ.....	6
1.1. Amaç.....	7
1.2. Önem.....	8
2. İLGİLİ ÇALIŞMALAR.....	8
3. ÖNERİLEN SİSTEM.....	13
3.1. İş Akış Şeması.....	14
3.2. Veri Seti.....	14
3.3. Veri Ön İşleme.....	15
3.4. Derin Öğrenme Mimarisi Seçimi.....	15
3.5. Model Oluşturma ve Eğitimi.....	16
3.6. Eğitim Hiper-Parametreleri	16
3.7. Performans Değerlendirme Metrikleri.....	17
3.8. Kullanıcı Arayüzü.....	17
4. BULGULAR.....	18
5. TARTIŞMA VE SONUÇ.....	19
KAYNAKLAR.....	21

ŞEKİL LİSTESİ

	Sayfa No
Şekil 1.1.	6
Şekil 1.2.	7
Şekil 2.1.	8
Şekil 2.2.	9
Şekil 2.3.	10
Şekil 2.4.	11
Şekil 2.5.	12
Şekil 3.1.	14
Şekil3.2.1	14
Şekil3.4.1	15
Şekil 4.1.	18
Şekil 4.2.	19

TABLO LİSTESİ

	Sayfa No
Tablo3.6.1.	16
Tablo 4.1.	18

SİMGE VE KISALTMA LİSTESİ

Kısaltmalar	Açıklama
IEEE	: Institute of Electrical and Electronics Engineers
IT	: Information Technology
GAN	: Generative Adversarial Network
CNN	: Convolutional Neural Network
DFDC	: Deepfake Detection Challenge
AUC	: Area Under the Curve
PDD	: Presidential Deepfake Dataset
TTS	: Text-to-Speech
AI	: Artificial intelligence
LSTM	: Long Short-Term Memory
rPPG	: Remote Photoplethysmography
FF++	: FaceForensics++
MTCNN	: Multi-task Cascaded Convolutional Neural Network

ÖZET

LİSANS TEZİ

YAPAY ZEKA TARAFINDAN ÜRETİLEN VİDEOLARI TESPİT EDEN UYGULAMA

MERVE EDİZ

**Kırşehir Ahi Evran Üniversitesi
Mühendislik Mimarlık Fakültesi
Bilgisayar Mühendisliği Bölümü**


Danışman: Dr.Öğr.Üyesi Volkan Güneş

Günümüzde dijital medya platformlarında yapay zekâ ile üretilen sahte içeriklerin sayısı hızla artmaktadır. Bu içerikler, özellikle video formatında üretildiğinde, bireyleri yanıltma, yanlış bilgi yayma ve toplumsal güveni zedeleme gibi ciddi sonuçlar doğurabilmektedir. Yapay zekâ ile üretilmiş videolar, derin öğrenme yöntemleri kullanılarak oluşturulan ve gerçek görüntülerden ayırt edilmesi çok zor olan sahte videolardır. Bu nedenle, yapay zekâ tarafından üretilmiş videoları tespit edebilen bir sisteme ihtiyaç duyulmaktadır. Bu projede, video içeriklerinin analiz edilerek gerçek veya yapay zekâ ürünü olup olmadığının tespit edilmesi amaçlanmaktadır. Geliştirilen sistemde derin öğrenme algoritmaları ve görüntü işleme teknikleri kullanılarak videolar üzerinde model eğitimi ve sınıflandırma işlemleri gerçekleştirilmiştir. Böylece, yapay zekâ tarafından üretilmiş sahte videoların tespiti için güvenilir ve uygulanabilir bir yaklaşım sunulmuştur.

Anahtar Kelimeler: Yapay Zekâ, Derin Öğrenme, Video Analizi, Deepfake Tespiti


1. GİRİŞ

Son yıllarda yapay zekâ ve derin öğrenme alanlarında yaşanan gelişmeler, insan yüzlerini, seslerini ve hareketlerini gerçeğinden ayırt edilemeyecek biçimde taklit edebilen “deepfake” teknolojilerinin ortaya çıkmasına neden olmuştur. Özellikle politikacılar, sanatçılar veya sıradan bireyler hakkında sahte videoların dolaşıma sokulması, yanlış bilgilendirme ve itibar zedeleme risklerini artırmıştır. Bu projede, açık kaynaklı bir veri seti kullanılarak gerçek ve sahte videoları ayırt edebilen bir derin öğrenme modeli geliştirilmiştir. Projenin temel amacı, görüntü çerçevelerinden elde edilen yüz bölgelerini analiz eden bir model eğitmek ve bu modeli kullanarak video içeriğinin gerçeklik olasılığını tahmin etmektir. Bu model, kullanıcıya bir arayüzle bütünleştirilerek pratik bir uygulama olarak sunulmuştur. Geliştirilen sistem, dijital medya platformlarında paylaşılan videoların doğruluğunu hızlı ve güvenilir biçimde analiz etmeyi hedeflemektedir. Bu çalışma, dijital güvenliği artırmak ve yanlış bilgi yayılımını azaltmak için önemli bir adım olarak değerlendirilebilir.



Şekil 1.1. Deepfake Fotoğraf Tespitinin İş Akış Diyagramı[1]

Şekil 1.1.’de gösterilen diyagram, deepfake fotoğraf tespiti sürecinin temel mantığını gösteren GAN mimarisini özetlemektedir. Sistem, temelde Üretici(Generator) ve Ayırt Edici(Discriminator) olmak üzere iki ana bileşenden oluşur. Üretici, rastgele girdileri kullanarak sahte görüntüler oluştururken, Ayırt Edici ise hem gerçek görüntülerden gelen Gerçek Örnekleri (Real Sample) hem de Üretici tarafından üretilen Sahte Örnekleri (Generated Sample) alarak bunların gerçek mi yoksa sahte mi olduğuna dair bir sınıflandırma yapar. Bu çalışma, deepfake videoların tespiti projesinin bir parçası olarak, deepfake teknolojisinin kökenini ve arkasındaki temel yapay zekâ mantığını okuyucuya sunmak amacıyla rapora dahil edilmiştir.



Şekil 1.2. Deepfake Video Tespitinin İş Akış Diyagramı[2]

Şekil 1.2.'de gösterilen diyagram, deepfake video tespiti için önerilen bir sistemin bütünsel çalışma akışını göstermektedir. İşlem, yüklenen videoların kârelere ayrılmasıyla başlar; ardından Face Detection ve Face Cropping adımlarıyla sadece yüz bölgesine odaklanılır. Ön işlenmiş veriler, Inception ResNet v2 ve Xception gibi derin öğrenme modelleriyle eğitilir. Elde edilen model Confusion Matrix ile değerlendirilir ve model dışa aktarılır. Bu şekil, projenin giriş bölümünde, çalışmanın genel metodolojisini okuyucuya şematik olarak anlatmak ve projenin yol haritasını görselleştirmek amacıyla kullanılmıştır.

1.1. Amaç


Gelişen yapay zekâ teknolojileri ile birlikte gerçek ve yapay içerikler arasındaki farkın ayırt edilmesi giderek zorlaşmıştır. Özellikle deepfake olarak adlandırılan, derin öğrenme yöntemleriyle oluşturulmuş sahte video içerikleri; yanlış bilgi yayılımı, itibar zedelenmesi ve güvenlik açıkları gibi ciddi sorunlara yol açmaktadır. Bu nedenle, video içeriklerinin gerçekliğini analiz ederek sahte olup olmadığını tespit eden güvenilir sistemlere ihtiyaç duyulmaktadır. Bu proje, derin öğrenme ve görüntü işleme yöntemlerinden biri olan CNN tabanlı bir model kullanarak deepfake videoların tespit edilmesini amaçlamaktadır. Hazırlanan sistem, verilen video verilerini analiz ederek içeriğin gerçek veya sahte olduğunu sınıflandıracaktır. Böylece sahte içeriklerin yayılımının önüne geçilmesi, kullanıcıların ve kurumların dijital ortamlarda daha güvenli bir şekilde bilgiye erişmesi hedeflenmektedir.

1.2. Önem

Günümüzde yapay zekâ tarafından üretilmiş videoların sayısı hızla artmakta ve bu durum yanlış bilgi yayılması, itibar kaybı ve dolandırıcılık gibi ciddi sorunlara yol açmaktadır. Yapılan çalışma, bir videonun gerçek mi yoksa yapay zekâ tarafından üretilmiş mi olduğunu gerçek zamanlı olarak tespit etme işlevini gerçekleştirmektedir. Bu sayede sahte içeriklerin yayılması engellenebilir ve kullanıcılar doğru bilgiye erişebilir. CNN tabanlı tespit sistemi, videolardaki yapay izleri analiz ederek doğru ve güvenilir sonuçlar sunacak, olası yanlış bilgilendirme ve kötü niyetli kullanım risklerini azaltacaktır. Uygulama konuyu her yönüyle ele aldığı için hem bireysel kullanıcılar hem de kurumlar için güvenli ve bilinçli bir dijital ortam sağlama açısından önem taşımaktadır.

2. İLGİLİ ÇALIŞMALAR


Sumaiya Thaseen Ikram, Priya V, Shourya Chambial, Dhruv Sood ve Arulkumar V tarafından yapılan çalışmada, manipölasyon izlerini tespit ederek deepfake videoların belirlenmesi için bir Hibrit CNN derin öğrenme modeli geliştirilmiştir. Çalışmanın temel amacı, mevcut deepfake tespit algoritmalarının performansını, farklı video işleme tekniklerinin özelliklerini birleştiren yeni bir mimari ile artırmaktır. Geliştirilen hibrit model mimarisi, Xception-Net ve EfficientNet B0'ın birleşimi üzerine kurulmuştur. Bu birleşim, modelin hem hafif olmasını hem de derinlemesine özellik çıkarma yeteneğini korumasını sağlamıştır. Modelin eğitiminde DFDC Preview ve Celeb-DFv2 veri setleri kullanılmıştır. Model, deepfake videoların tespiti için öncelikle video kareleri üzerinde yüz tespiti yapmış ve yüzü merkeze alarak kırpma işlemi uygulamıştır. Eğitilen hibrit model, Celeb-DFv2 veri seti üzerinde %96.35 doğruluk oranına, DFDC Preview veri setinde ise %95.69 doğruluk oranına ulaşmıştır. Bu sonuçlar, deepfake video tespiti için umut verici ve rekabetçi bir çözüm olduğunu kanıtlamaktadır [2].



Şekil 2.1. Geliştirilen Sistemin İş Akış Diyagramı [2].

Şekil 2.1.'de gösterilen diyagram, Sumaiya Thaseen Ikram ve ekibinin deepfake tespiti için geliştirdiği Hibrit CNN modelinin çalışma aşamalarını detaylandırmaktadır. Diyagram, ham verinin Deepfake ve Dataset olarak ayrılmasını ve ön işleme adımlarını göstermektedir. Sistem, Inception v2 ve Xception gibi modelleri birleştirerek oluşturulan Hibrit Son Model ile sınıflandırma yapar. Bu görsel, ilgili bölümde, literatürdeki rekabetçi bir Hibrit CNN modelinin teknik mimarisini ve eğitim sürecini somut bir şekilde göstermek için seçilmiştir.

Şahin Korkmaz ve Mustafa Alkan tarafından yapılan çalışmada, derin öğrenme algoritmaları kullanılarak deepfake videoların tespiti için bir sınıflandırma modeli geliştirilmiştir. Bu çalışmada, EfficientNet model ailesi kullanılarak yeni bir model ortaya konulmuştur. Modelin eğitilmesinde, DFDC veri seti kullanılmıştır. Bu veri seti, yaklaşık 100.000 sahte ve 19.000 gerçek videodan oluşmaktadır. Video karelerindeki görsel tutarsızlıkları tespit etmek amacıyla, ön işleme aşamasında videolar 32 kare ile sınırlandırılmış ve yüzler BlazeFace dedektörü ile çıkarılmıştır. Veri seti üzerinde yapılan eğitim ve test sonuçlarında, EfficientNetB4 modeli en yüksek performansı göstermiş ve yaklaşık %91'lik bir doğruluk elde edilmiştir. Geliştirilen bu modelin, literatürdeki benzer çalışmalarla kıyaslandığında rekabetçi sonuçlar ürettiği belirtilmiştir [3].



Şekil 2.2. Geliştirilen Sistemin Tespit Mimarisi [3]


Şekil 2.2.'de gösterilen şekil, Şahin Korkmaz ve Mustafa Alkan tarafından EfficientNet model ailesi kullanılarak geliştirilen deepfake tespit mimarisinin aşamalarını göstermektedir. Mimarinin ilk aşaması olan Ön İşleme, Çerçeve Çıkarma ve Yüz Çıkarma adımlarını içerir. Bu aşamayı, Detaylı Ön İşleme adımları takip eder. Ön işleme sonrasında veriler, tahmin aşamasında EfficientNetB4 tarafından gerçek veya sahte olarak sınıflandırılır. Bu görsel, ilgili kısımda, özellikle veri ön işleme aşamalarının detaylarını ve genel sınıflandırma akışını vurgulamak amacıyla rapora dahil edilmiştir.

Matthew Groh, Aruna Sankaranarayanan, Nikhil Singh, Dong Young Kim, Andrew Lippman ve Rosalind Picard tarafından yapılan çalışmada, insanların siyasi konuşma deepfake'lerini ayırt etme başarısı, 5 önceden kayıtlı randomize deney ve 2.215 katılımcı (Ek olarak 41.313 katılımcı) ile incelenmiştir. Çalışma, yanlış bilginin yayılma oranları, ses kaynakları ve medya sunum şekillerinin deepfake içeriklerin algılanması üzerindeki etkisini değerlendirmeyi amaçlamıştır. Deneylerde Donald Trump ve Joseph Biden'in konuşmalarını içeren PDD videoları kullanılmış; deepfake'ler, seslendirme sanatçısı ve TTS algoritmaları ile üretilmiştir. Yapılan analizler, katılımcıların sesli ve görsel bilgiye erişebildiklerinde

deepfake'leri ayırt etme konusunda önemli ölçüde daha doğru olduğunu ortaya koymuştur. Bu durum, insanların ayırım yaparken ne söylediğinden çok nasıl söylendiğine odaklandığını göstermiştir. En kritik bulgu ise, TTS algoritmaları ile üretilen deepfake'lerin, seslendirme sanatçısı sesi kullanılan aynı deepfake'lere göre insanlar tarafından ayırt edilmesinin anlamlı ölçüde zor olduğudur. Bu sonuçlar, deepfake teknolojisinin tehlike arz eden seviyeye yaklaştığını göstermektedir [4].

Matthew Groh, Ziv Epstein, Chaz Firestone ve Rosalind Picard tarafından yapılan çalışmada, insanların deepfake videoları tespit etme performansı, dönemin lider öğrenim modeli ile karşılaştırılmıştır. Çalışmanın temelini, 15.016 katılımcı ile gerçekleştirilen iki çevrimiçi deney oluşturmaktadır. Deepfake videoların tespitinde, sıradan gözlemcilerin performansının lider model ile benzer doğrulukta olduğu, ancak her iki tarafın da farklı türde hatalar yaptığı belirlenmiştir. Araştırmacılar, bu önde gelen modelin, EfficientNet B-7 kullandığını ve %65 doğruluk skoruna ulaştığını belirtmişlerdir. Makalenin en kritik bulgusu, insan ve makine tahminlerini birleştiren hibrit bir sistemin, diğerlerinden daha yüksek doğruluk sağladığıdır. Ancak modelin yanlış tahminlerinin, insanları yanlış cevap vermeye yönlterek katılımcıların doğruluğunu düşürdüğü de gözlemlenmiştir. Ayrıca, yüz manipülasyonlarının insan performansını engellediği, ancak makine modelinin performansını büyük ölçüde etkilemediği tespit edilmiştir [5].

Muhammad Javed, Zhaohui Zhang, Fida Hussain Dahri ve Asif Ali Laghari tarafından yapılan çalışmada, gerçek zamanlı deepfake video tespiti için Göz Hareketi Analizini kullanan Hibrit Derin Öğrenme yaklaşımı geliştirilmiştir. Çalışma, deepfake içerikte genellikle eksik olan veya tutarsız olan yüzdeki ince ayrıntıları, özellikle retinadaki ışık yansıması ve göz hareketlerini analiz ederek tespit etmeyi amaçlamıştır. Geliştirilen model, MesoNet4 ve ResNet-101 mimarilerinin entegrasyonu ile oluşturulmuştur. Bu iki ağın çıktıları bir görünüm modeli kullanılarak birleştirilmiştir. Model, FaceForensics++, CelebV1 ve CelebV2 veri setleri üzerinde değerlendirilmiştir. Elde edilen bulgular, modelin FaceForensics++ üzerinde %98.73 doğruluk ve CelebV2 üzerinde %97.90 doğruluk elde ettiğini göstermiştir. Bu sonuçlar, göz hareketlerinin analizi ile desteklenen hibrit derin öğrenme modelinin, gerçek zamanlı deepfake tespiti için oldukça etkili bir çözüm sunduğunu kanıtlamaktadır [6].




Şekil 2.3. Sistemin Önerilen Çalışma Akışı [6].

Şekil 2.3.'te gösterilen akış, Muhammad Javed ve ekibinin göz hareketi analizini kullanan yaklaşımın çalışma mimarisini açıklamaktadır. Sistem, videoyu ince ayrıntılar için Göz Hareketi Analizi ve Yüz Tespiti odaklı iki kola ayırır. Temel deepfake tespiti, iki mimarinin entegrasyonu ile elde edilen çıktılarının bir Görünüm Modeli ve Sonuç Birleştirme ile birleştirilmesine dayanır. Bu görsel, ilgili bölüme, yüz manipülasyonları dışında biyolojik sinyallere odaklanan yenilikçi bir hibrit modelin yapısını göstermek amacıyla eklenmiştir.

Yupeng Zhang, Zongwei Pang, Shanyuan Huang, Chengyou Wang ve Xiao Zhou tarafından yapılan çalışmada, deepfake tespiti teknolojileri üzerine kapsamlı bir literatür incelemesi sunulmuştur. Bu çalışma, deepfake'lerin yol açtığı yanlış bilgilendirme, gizlilik ihlali ve kamuoyunu manipülasyon gibi sorunlar karşısında, AI ile üretilmiş içeriğin tespit edilmesinin önemini vurgulamaktadır. Makalede, AI ile oluşturulan görsellerin tespiti ve deepfake video tespiti olmak üzere iki ana kategori ele alınmıştır. Tespit yöntemleri ise genellikle manipülasyonun bıraktığı gözle görülemeyen çözünürlük ve sıkıştırma anormallikleri, dudak senkronizasyonu hataları gibi fiziksel izlere ve derin öğrenme modellerine dayalı özellik çıkarma yöntemlerine odaklanmıştır. Bu inceleme, alanındaki son gelişmeleri özetlemiş ve tekniklerin zorluklarına dikkat çekmiştir [7].

Robail Yasrab, Wanqi Jiang ve Adnan Riaz tarafından yapılan çalışmada, deepfake videoların tespit edilmesi için üst vücut dilini ve hareket kalıplarını kullanan yenilikçi bir derin öğrenme yöntemi sunulmuştur. Bu çalışma, deepfake oluşturma tekniklerinin bireyin kendine özgü vücut hareketlerindeki tutarsızlıkları gideremediği varsayımına dayanmaktadır. Önerilen yöntem, videolardan vücut pozlarını ve iskelet noktalarını çıkarmak için OpenPose gibi sistemlerden faydalanmıştır. Elde edilen bu zamansal hareket verilerini analiz etmek ve videonun gerçek mi sahte mi olduğunu sınıflandırmak için ise LSTM ağı kullanılmış ve eğitilmiştir. Bu yaklaşım, deepfake test setinde %94,39'luk bir doğruluk elde etmiş; bu sonuç, yüz özelliklerine dayanan kıyaslama modellerini geride bırakmıştır; vücut dilini temel alan tespit yöntemlerinin, gelecek vadede bir çözüm olduğunu kanıtlamıştır [8].



Şekil 2.4. Geliştirilen Sistemin Önerilen Aşamaları [8].


Şekil 2.4.'te gösterilen şekil, üst vücut dili ve hareket kalıplarını kullanan deepfake tespit yönteminin çalışma akışını göstermektedir. Sistem, giriş videosundan OpenPose ile vücut pozlarını ve iskelet noktalarını belirler. Çıkarılan bu zamansal hareket verileri, bir LSTM ağı kullanılarak eğitilir ve videoyu gerçek veya sahte olarak sınıflandırır. Bu yöntem, yüz manipülasyonlarını atlayarak davranışsal tutarsızlıkları yakalaması ve yüksek doğruluk elde etmesi nedeniyle rapora alternatif bir tespit stratejisi olarak eklenmiştir.

Intel tarafından geliştirilen FakeCatcher uygulaması, biyolojik sinyal analizi üzerine kurulmuş yenilikçi bir yaklaşımdır. Bu teknolojinin temel hipotezi, canlı bir insan yüzündeki kan akışındaki değişikliklerin neden olduğu görünmez biyometrik ipuçlarının, deepfake oluşturma algoritmaları tarafından kusursuzca taklit edilemeyeceğidir. FakeCatcher, bir

videoyu analiz ederken, insan derisinin rengindeki ince deęişimleri tespit ederek nabız ve kan akışı gibi yaşamsal belirtileri ölçen rPPG tekniğini kullanır. Bu yöntem sayesinde, videodaki yüzün farklı bölgelerinden gelen renk deęişim desenleri haritalanır ve deepfake'lerde genellikle eksik veya tutarsız görünen gerçek biyolojik sinyal ritimleri aranır. FakeCatcher, deepfake'leri gerçek zamanlı olarak, yani saniyenin onda biri kadar kısa bir sürede ve %96'ya kadar bir doğruluk oranıyla tespit edebilmektedir. Bu teknoloji, manipüle edilmesi çok zor olan insan fizyolojisine dayalı olup alana önemli bir katkı sağlamaktadır [9].

Honor tarafından yapılan Cihaz İçi Yapay Zekâ Deepfake Tespiti uygulaması, deepfake tespiti yükünü kullanıcıdan alıp doğrudan bir cihaza taşıyarak çözüm sunmaktadır. Geleneksel olarak tespit işlemleri bulut sunucularında yapılırken, bu araç, videoları doğrudan cihazın içinde tarar. Bu, hem gecikmeyi ortadan kaldırır hem de hassas kullanıcı verilerinin gönderilmesini engeller, gizlilięi sağlar. Tespitte kullanılan yöntem, videolardaki bozuk kareler veya doğal olmayan yüz hareketleri gibi işaretleri arayan yapay zekâ algoritmalarına dayanmaktadır. Honor Başkan Yardımcısı Jianfa Sun'a göre bu özellik, tespiti cihaza devrederek kullanıcılara karmaşık yapay zekâ çağında güvenle hareket etme yetkisi vermektedir. Özellik, popüler üçüncü taraf mesajlaşma (WeChat, WhatsApp, Messenger) ve kısa video uygulamalarında da çalışarak deepfake korumasını günlük iletişim kanallarına entegre etmesi açısından literatürde uygulamalı bir ilktir [10].

Dr. Sandeep ve Dr. Inderjot tarafından yürütölen bu çalışmada, deepfake videoların tespiti için yüz özelliklerinin yanı sıra duygusal çeşitlilik ve istatistiksel güven aralığı gibi davranışsal ve yüz analizi kalıplarına dayalı yeni bir sezgisel algoritma kullanılmıştır. Bu yaklaşımın temel amacı, yapay zeka tarafından üretilen videolardaki doğallıktan uzak, robotik davranışları tespit etmektir. Geliştirilen sezgisel algoritma, videonun her karesindeki yüzü analiz ederek bir dizi koşula göre karar vermektedir. Bu koşullardan biri, videonun tamamında çok düşük duygusal çeşitliliğin olması ve bunların karelerin %75'den fazlasında görünmesidir; bu durum yapay zekanın neden olduęu tekdüze bir ifadeye işaret eder. İkinci önemli kriter, duyguların ortalama güven aralığının %95'in üzerinde olmasıdır; bu kadar yüksek düzey, deepfake kabul edilir. Ayrıca, hiçbir karede yüz tespit edilememesi veya karelerin %50'sinden fazlasında yüz tespitinin başarısız olması gibi yapısal sorunlar da deepfake belirtileri olarak ele alınmıştır. Tüm bu koşulları sağlamayan videolar, gerçek olarak sınıflandırılmaktadır [11].



Şekil 2.5. Projede Oluşan Çıktılar [11].

Şekil 2.5.'te gösterilen görsel, ilgili çalışmada kullanılan algoritmanın çıktılarını özetlemektedir. Üstteki analiz çıktısı, çok düşük Duygu Çeşitliliği ve aşırı yüksek Ortalama Duygu Güven Aralığı (%97.66) kriterlerini karşılayarak Yapay Zekâ İçeriği olarak yorumlanmıştır. Alt kısımda ise, daha çeşitli ve doğal ifadeler gösterdiği için Gerçek İnsan İfadeleri içerdiği sonucuna varılmıştır. Şekil, tespitte davranışsal izlerin kritik rol oynadığını ve sonuçlarda nasıl etki gördüğünü göstermek amacıyla kullanılmıştır.

Muhammed Emin Arslan ve Erdem Güler tarafından yapılan bu çalışmada, deepfake videoların tespiti için MesoNet4 adı verilen bir CNN mimarisi kullanılmıştır. Projenin temel amacı, deepfake üretiminden kaynaklanan ve insan gözüyle zor fark edilen mikro dokusal kusurları ve manipülasyon izlerini tespit etmektir. Bu amaca ulaşmak için, deepfake videolar öncelikle işlenmiş, video kareleri 256x256 piksel ayarlanmış ve deepfake tespitinde yaygın olarak kullanılan görüntüler kullanılarak eğitilmiştir. Model, Adam optimizasyon algoritması ve Mean Squared Error fonksiyonu kullanılarak eğitilmiş ve gerçek-sahte görüntüler üzerinde ikili sınıflandırma yapması hedeflenmiştir. Bu yaklaşım, deepfake tespiti alanında ağırlığı az, yüksek hassasiyete sahip bir model geliştirme çabasına örnek teşkil etmektedir [12].


Ahsen Hatipoğlu ve Orhan Arslan tarafından sunulan bu çalışmada, deepfake video tespiti için çok aşamalı, standart bir derin öğrenme tabanlı yöntem kullanılmıştır. Projenin ana hedefi, manipüle edilmiş videoları gerçek içerikten ayırt etmektir. Bu amaçla ilk olarak, dlib ve OpenCV gibi kütüphaneler kullanılarak videolardan kareler çıkarılmış ve her karedeki yüzler tespit edilerek kırılmıştır. İkinci aşamada, tespit edilen yüzler kullanılarak bir CNN modeli eğitilmiştir. Modelin mimarisi, derin öğrenmenin standart katmanlarını içerir ve sahte ile gerçek görüntüleri ayırt etmek üzere tasarlanmıştır. Model eğitimi, veriyi eğitim ve test setlerine bölerek yapılmış ve en iyi performansı gösteren modeli kaydetmek için ModelCheckpoint geri çağrı mekanizması kullanılmıştır. Çalışma, deepfake'lerin tespiti sürecinde yüz odaklı veri hazırlığının ve bunu takiben klasik bir CNN mimarisiyle sınıflandırmanın uygulanmasına örnek teşkil etmektedir [13].

Afchar ve ekip arkadaşları tarafından yapılan bir çalışmada, görüntülerin mezoskopik özelliklerine odaklanmak için daha az sayıda katmanla tasarlanmış MesoNet adında başka bir CNN tabanlı model önerilmiştir. Videoların sıkıştırılması nedeniyle ve makroskopik düzeyde görüntü gürültüsüne dayalı mikroskobik analiz mümkün olmadığından, mezoskopik unsurlara odaklanmak için bir ara yöntem benimsenmiştir. CNN katmanları kullanan Meso-4 ve Inception modüllerine dayanan MesoInception-4 adlı iki farklı model ortaya koyulmuştur. Bu modellerin değerlendirilmesi internette toplanan deepfake videolar üzerinde yapılmakta ve Deepfake videoları için ortalama %98 doğrulukla tespit oranı elde edilmektedir [14].

3. ÖNERİLEN SİSTEM

Günümüzde derin öğrenme tekniklerinin hızla gelişmesiyle, deepfake ciddi bir sosyal ve etik sorun haline gelmiştir. Bu, özellikle kamuoyunu yanıltma riskini beraberinde getirmektedir. Bu projede, Python, PyTorch ve gelişmiş bir CNN mimarisi olan XceptionNet kullanılarak Deepfake videoları yüksek doğrulukla tespit edebilen, gerçek zamanlı çalışmaya uygun bir sistem önerilmektedir. Sistem, deepfake tespitinde kanıtlanmış bir yöntem olan Transfer Öğrenme stratejisini benimseyerek, FaceForensics++ (C23) veri seti üzerinde çalışmaktadır. Modelin performansını maksimize etmek için videolar sadece yüz bölgesine odaklanacak şekilde ön işlenmektedir. Bu model ve veri hazırlama yaklaşımı, sistemin hem verimli hem de güvenilir olmasını sağlamaktadır. Önerilen sistemin detayları ve izlenecek adımlar bölümün devamında yer almaktadır.

3.1. İş Akış Şeması




Şekil 3.1. Proje İş Akış Şeması

Şekil 3.1.'de gösterilen şema, sistemin videoyu kabul etmesinden başlayarak analiz sürecini yürütmesini ve nihai tahmin çıktısını kullanıcıya sunmasını içeren temel operasyonel adımları temsil etmektedir.

3.2. Veri Seti

Bu projede, derin öğrenme modelinin eğitimi ve test edilmesi için geniş kapsamlı ve akademik standartlara uygun olan FaceForensics++ (FF++) veri seti kullanılmıştır. Veri seti, farklı videolar üzerine uygulanmış dört ana manipülasyon tekniğini içerir: DeepFakes (DF), Face2Face (F2F), Neural Textures (NT) ve FaceSwap (FS). Veri seti, yaklaşık 1000 orijinal video ve bu videolar üzerinden üretilmiş 50.000'den fazla manipüle edilmiş video içerir. Hesaplama karmaşıklığını ve eğitim süresini yönetilebilir seviyede tutmak için ise, veri setinin C23 sıkıştırma kalitesine sahip versiyonu kullanılmıştır.



Şekil 3.2.1. FaceForensics++ veri setinden bir örnek [15].


Şekil 3.2.1.'de gösterilen görsel, önerilen sistemin eğitimi için kullanılan FaceForensics++ veri setinden alınan yüz örneklerini göstermektedir. Bu şekil, Önerilen Sistem başlığıyla, modelin deepfake izlerini ve sadece yüz bölgesine odaklanmış olan veri yapısını okuyucuya örnek olması amacıyla somut bir şekilde sunulmaktadır.

3.3. Veri Ön İşleme

Modelin eğitim etkinliğini ve gerçek zamanlı sistem performansını artırmak amacıyla, FF++ veri setindeki video dosyaları üzerinde ön işleme adımları uygulanmıştır. Hesaplama yükünü optimize etmek ve model girişini standardize etmek amacıyla, video süresinden bağımsız olarak her videodan eşit aralıklarla seçilmiş 32 frame örneklenerek bir görüntü havuzu oluşturulmuştur. Örneklenen her karede, deepfake manipülasyon izlerine odaklanmak amacıyla, dlib kütüphanesi kullanılarak yüz sınırları tespit edilmiştir. Yüz sınırlarının ve referans noktalarının hassas bir şekilde belirlenmesi için dlib kütüphanesinin sunduğu ve 68 farklı karakteristik noktayı tanımlayabilen önceden eğitilmiş shape_predictor_68_face_landmarks.dat modeli kullanılmıştır [16]. Tespit edilen yüzlere, göz ve burun koordinatları referans alınarak 'yüz hizalama' (face alignment) işlemi uygulanmış ve geometrik düzeltme sağlanmıştır. Kırılan tüm bu yüz görüntüleri, 256 x 256 piksel boyutuna yeniden boyutlandırılmıştır. Son olarak, görüntü pikselleri önce 0-1 aralığına indirgenmiş, ardından modelin daha kararlı çalışması için [-1, 1] aralığına normalize edilmiştir. Böylelikle veri seti CNN model tarafından işlenmeye uygun hale getirilmiştir.

3.4. Derin Öğrenme Mimarisi Seçimi

Mimari için CNN tabanlı bir yaklaşım benimsenmiştir. Bu alandaki akademik çalışmalarda performans ve verimlilik sağladığından temel mimari olarak XceptionNet seçilmiştir. XceptionNet, Google tarafından geliştirilmiş olup, geleneksel CNN'lerdeki standart evrişim katmanlarının yerine Derinlik Ayrılabilir Evrişim (Depthwise Separable Convolution) katmanlarını kullanır [17]. Bu yapı, hem modelin parametre sayısını ve hesaplama maliyetini düşürür hem de modelin daha geniş bir özellik yelpazesini öğrenmesini sağlar. Projede, XceptionNet mimarisi, derin öğrenme eğitimi hızlandıran ve yüksek doğruluk sağlayan Transfer Öğrenme yöntemiyle uygulanmıştır. Model, büyük ölçekli görüntü tanıma veri kümesi olan ImageNet üzerinde önceden eğitilmiş ağırlıklarla yüklenmiştir. Bu, modelin sıfırdan eğitimi gerektirmeyerek, sınırlı deepfake veri seti üzerinde daha hızlı ve başarılı bir ince ayar (Fine-Tuning) yapılmasını mümkün kılmaktadır.



Şekil 3.4.1. Xception Mimarisi [17].

Şekil 3.4.1.'de gösterilen mimari, proje temelini oluşturan CNN mimarisi XceptionNet'in Giriş, Orta ve Çıkış Akışlarından oluşan katman yapısını detaylandırmaktadır. Bu teknik tasarım, modelin parametrik verimliliğini artırıp hesaplama maliyetini önemli ölçüde düşürürken yüksek doğruluk potansiyeli sunar. Şekil, tez çalışmasında seçilen temel mimarinin teknik yapısını ve optimizasyon gerekçesini görselleştirmek amacıyla rapora dahil edilmiştir.

3.5. Model Oluşturma ve Eğitimi

Model eğitimi, Python programlama dili kullanılarak PyTorch derin öğrenme kütüphanesi aracılığıyla gerçekleştirilmiştir. Model, sıfırdan eğitim yerine, mevcut bilgi birikimini kullanmayı temel alan Transfer Öğrenme stratejisi üzerine kurulmuştur. Bu strateji, deepfake tespiti projesinin eğitim süresini ve hesaplama gereksinimlerini önemli ölçüde düşürürken, yüksek genelleme yeteneği sağlar. Projede kullanılan XceptionNet mimarisi, başlangıçta ImageNet veri kümesi üzerinde eğitilmiş olan hazır ağırlıklarla yüklenmiştir. Ardından XceptionNet mimarisi üzerinde Transfer Öğrenme uygulanmıştır. Katman dondurma işlemi yerine, modelin tamamı düşük bir öğrenme oranıyla eğitilerek (Full Fine-Tuning) hem genel görsel özelliklerin korunması hem de deepfake'e özgü mikro desenlerin öğrenilmesi sağlanmıştır. Modelin sonuna Deepfake ve Gerçek ayrımı yapan yeni bir sınıflandırma katmanı eklenmiş ve tüm ağ FaceForensics++ veri setiyle uçtan uca optimize edilmiştir.

3.6. Eğitim Hiper-Parametreleri

Modelin eğitilmesi için Tablo 1.1'de yer alan hiper parametreler kullanılmaktadır.

Hiper Parametreler	Değer
Epoch	10
Loss_Function	Cross-Entropy
Optimizer	Adam
Batch Size	32
Learning rate	0,0002
Girdi Boyutu	3

Tablo 3.6.1. Eğitimde Kullanılan Hiper Parametreler

Tablo 3.6.1.'de verilen hiper parametreler ile model eğitimi gerçekleştirilmiştir. Epoch değeri, veri setinin tamamının ağıdan kaç kez geçirileceğini ifade etmektedir. Öğrenme oranı, eğitim sırasında ağırlıkların ne oranda güncelleneceğini belirlemektedir. Kayıp fonksiyonu olarak çapraz entropi kullanılmış olup, sınıflandırma başarısını artırmak amacıyla Adam optimizasyon algoritması tercih edilmiştir. Bu parametreler, literatürde benzer çalışmalar incelenerek ve deneysel sonuçlar göz önünde bulundurularak belirlenmiştir.

3.7. Performans Değerlendirme Metrikleri

Bu çalışmada geliştirilen deepfake tespit modelinin performansı, ikili sınıflandırma problemleri için yaygın olarak kullanılan değerlendirme metrikleri ile analiz edilmiştir. Gerçek ve sahte video içeriklerinin doğru şekilde ayırt edilebilmesi amacıyla birden fazla performans ölçütü kullanılmıştır.

3.7.1 Doğruluk (Accuracy – ACC)

Doğruluk metriği, model tarafından doğru sınıflandırılan örneklerin toplam örnek sayısına oranını ifade etmektedir. Bu metrik, modelin genel sınıflandırma başarısını ölçmek amacıyla kullanılmaktadır.

3.7.2 AUC (Area Under Curve)

AUC metriği, ROC (Receiver Operating Characteristic) eğrisi altında kalan alanı temsil etmektedir. Modelin farklı eşik değerlerinde gerçek ve sahte sınıfları ayırt edebilme yeteneğini göstermektedir. AUC değerinin 1'e yaklaşması, modelin ayırt ediciliğinin yüksek olduğunu ifade etmektedir.

3.7.3 EER (Equal Error Rate)

EER metriği, yanlış kabul oranı ile yanlış reddetme oranının eşit olduğu noktayı ifade etmektedir. Bu metrik, gerçek ve sahte sınıflar arasındaki dengeyi değerlendirmek amacıyla kullanılmaktadır. Düşük EER değeri, model performansının daha iyi olduğunu göstermektedir.

3.7.4 Average Precision (AP)

Average Precision metriği, Precision–Recall eğrisi altında kalan alanı temsil etmektedir. Modelin sahte içerikleri farklı eşik değerlerinde ne kadar tutarlı bir şekilde tespit edebildiğini ölçmektedir.

3.8. Kullanıcı Arayüzü

Geliştirilen sistemde kullanıcı arayüzü, Python tabanlı Streamlit kütüphanesi kullanılarak geliştirilmiş olup, model tarafından üretilen tahmin sonuçlarını kullanıcıya web tabanlı bir arayüz üzerinden sunacak şekilde yapılandırılmıştır. Arayüz üzerinden kullanıcı, analiz edilmesini istediği video dosyasını sisteme yükleyebilmektedir. Yüklenen video, arka planda çalışan deepfake tespit modeli tarafından otomatik olarak işlenmekte ve analiz süreci başlatılmaktadır. Kullanıcının herhangi bir teknik bilgiye sahip olmasına gerek kalmadan, yalnızca video seçimi yaparak sistemden sonuç alabilmesi hedeflenmiştir. Video analizi sırasında, sistem tarafından video kareleri belirli aralıklarla işlenmekte ve her bir kare üzerinden elde edilen tahmin sonuçları birleştirilerek video bazlı bir değerlendirme yapılmaktadır. Analiz tamamlandığında, kullanıcıya videonun gerçek veya sahte olma durumu arayüz üzerinde görsel olarak sunulmaktadır. Kullanıcı arayüzü tasarlanırken gereksiz karmaşadan kaçınılarak, kullanıcının yalnızca temel işlemleri gerçekleştirebileceği bir yapı oluşturulmuştur. Bu sayede sistem, farklı kullanıcı profilleri tarafından rahatlıkla kullanılacak bir uygulama haline getirilmiştir.


4. BULGULAR

Bu çalışmada deepfake video tespiti amacıyla geliştirilen sistemin performansı değerlendirilmiştir. Deneysel çalışmalar, FaceForensics++ veri seti kullanılarak gerçekleştirilmiş ve veri setine ait görüntüler üzerinde yüz kırpma ve ön işleme adımları uygulanmış framelelerden oluşan büyük bir veri havuzu oluşturulmuştur. Eğitim, doğrulama ve test süreçlerinde, kullanılan benchmark çalışmasının sağladığı önceden tanımlı veri bölünmesi esas alınmış olup, yüzdesel bir rastgele ayırım yapılmamıştır. Model eğitimi sonucunda, Xception mimarisi kullanılarak eğitilen derin öğrenme modeli, değerlendirme aşamasında %96,37 başarı oranına ulaşarak deepfake tespiti görevinde yüksek performans sergilemiştir. Geliştirilen uygulamanın çalışma prensibini somutlaştırmak amacıyla, sisteme verilen örnek bir fake video üzerinde elde edilen çıktı sonuçları incelenmiştir. Çalışan uygulamada örnek bir fake video için üretilen tahmin değerleri Tablo 4.1’de sunulmuştur.

	FAKE	REAL
DEEPPAKE VIDEO	0.9783	0.0217

Tablo 4.1. Örnek Bir Fake Video için Uygulama Tarafından Üretilen Tahmin Sonuçları


Önerilen modelin test seti üzerindeki genel başarısını değerlendirmek amacıyla kullanılan performans metrikleri Şekil 4.1’de sunulmuştur. Bu sonuçlara göre model, %96.37 AUC ve %96.05 AP değerlerine ulaşarak yüksek bir ayırt edicilik sergilemiştir. Sistemin genel doğruluk oranı (ACC) %87.00 olarak kaydedilirken, hata oranını temsil eden EER değerinin %11.00 seviyesinde kalması, modelin kararlı bir performans sergilediğini doğrulamaktadır.



Şekil 4.1. Model Performans Metriklerinin Karşılaştırmalı Analizi

Şekil 4.1.'de gösterilen performans metrikleri incelendiğinde; %96.37 AUC, %96.05 AP ve %87.00 ACC değerleri ile yüksek bir ayırt edicilik sergilediği görülmektedir.

Test verilerinden alınan örnek 100 videodaki tahminlerin sınıf bazlı dağılımı Şekil 4.2.'teki karmaşıklık matrisi üzerinden incelenmiştir. Matris verilerine göre model; 41 gerçek (Real) görüntüyü ve 46 sahte (Fake) görüntüyü doğru tahmin ederek yüksek bir sınıflandırma başarısı göstermiştir. Toplam 100 test örneği içerisinde yalnızca 9 görüntü yanlış pozitif (FP), 4 görüntü ise yanlış negatif (FN) olarak sınıflandırılmış; bu durum modelin manipüle edilmiş içerikleri tespit etmedeki hassasiyetini ortaya koymuştur.



Şekil 4.2. Test Verilerine Ait Karmaşıklık Matrisi

Şekil 4.2.'te gösterilen karmaşıklık matrisine göre model; 100 test örneğinden 41 gerçek ve 46 sahte görüntüyü doğru sınıflandırmış, manipüle edilmiş içerikleri tespit etmede yüksek hassasiyet göstermiştir.

5. SONUÇ VE TARTIŞMA

Bu çalışmada, dijital ortamlarda hızla yaygınlaşan ve güvenlik açısından önemli riskler oluşturan deepfake videoların tespit edilmesine yönelik bir sistem geliştirilmiştir. Derin öğrenme tabanlı yaklaşımlar, deepfake içeriklerin tespitinde geleneksel yöntemlere kıyasla daha başarılı sonuçlar verdiği için, bu çalışmada evrimsel sinir ağları temelli bir mimari tercih edilmiştir. FaceForensics++ veri seti kullanılarak gerçekleştirilen deneylerde, yüz odaklı ön işleme adımları uygulanmış ve video verileri sabit sayıda kare üzerinden temsil edilmiştir. Model eğitimi sürecinde Xception mimarisi kullanılarak geliştirilen derin öğrenme modeli, deepfake tespiti probleminde yüksek doğruluk oranı elde etmiştir. Eğitim ve değerlendirme aşamalarında, kullanılan benchmark çalışmasının sağladığı sabit veri bölünmesi esas alınmış ve bu sayede elde edilen sonuçların literatürdeki çalışmalarla karşılaştırılabilir olması sağlanmıştır. Elde edilen bulgular, geliştirilen modelin sahte ve gerçek video ayrımını başarıyla gerçekleştirebildiğini göstermektedir. Geliştirilen sistem, kullanıcıdan alınan video verisi üzerinde otomatik olarak işlem yapabilen ve sonuçları kullanıcıya anlaşılır biçimde sunan bir uygulama arayüzü ile desteklenmiştir. Bu sayede deepfake tespitinin yalnızca teorik bir çalışma olarak kalmayıp, pratikte kullanılabilir bir

uygulama haline getirilmesi amaçlanmıřtır. Uygulama, kullanıcıdan alınan videoları analiz ederek sahte olma olasılıđına dair tahmin sonuçlarını sunabilmektedir. Sonraki alıřmalarda, kullanılan veri setinin farklı senaryolar ve daha eřitli deepfake üretim teknikleri ile genişletilmesi planlanmaktadır. Ayrıca, farklı derin öğrenme mimarilerinin ve oklu model yaklaşımlarının bir arada kullanıldığı hibrit sistemlerin performans üzerindeki etkileri incelenebilir. Bunun yanında, gerek zamanlı deepfake tespitine yönelik optimizasyon alıřmalarının yapılması ve sistemin mobil platformlar üzerinde alıřabilecek şekilde geliştirilmesi, gelecekte ele alınabilecek önemli araştırma konuları arasında yer almaktadır.

KAYNAKLAR (Nümerik Referans Tekniği)

- [1]. IEEE Computer Society, “Deepfake Detection Techniques for Still Images: A Comparative Study”, *IEEE IT Professional Magazine*, 2024. [Online]. Erişilebilir: <https://www.computer.org/csdl/magazine/it/2024/02/10517327/1WAEdwDIUIE>. [Erişildi: 30 Ekim 2025].
- [2]. S. T. Ikram, P. V., S. Chambial, D. Sood ve A. V., “A Performance Enhancement of Deepfake Video Detection through the Use of a Hybrid CNN Deep Learning Model”, *International Journal of Electrical and Computer Engineering Systems (IJECEs)*, vol. 14, no. 1, 2023. [Online]. Erişilebilir: <https://ijeces.ferit.hr/index.php/ijeces/article/download/1719/261>. [Erişildi: 30 Ekim 2025].
- [3]. Korkmaz Ş., Alkan M., “Derin öğrenme algoritmalarını kullanarak deepfake video tespiti”, [Online]. Erişilebilir: <https://dergipark.org.tr/tr/pub/politeknik/issue/78812/1063104>. [Erişildi: 30 Ekim 2025].
- [4]. Groh M., Sankaranarayanan A., Singh N., Kim D.Y., Lippman A., Picard R., “Human Detection of Political Speech Deepfakes across Transcripts, Audio, and Video”, [Online]. Erişilebilir: <https://arxiv.org/abs/2202.12883>. [Erişildi: 30 Ekim 2025].
- [5]. Groh M., Epstein Z., Firestone C., Picard R., “Deepfake detection by human crowds, machines, and machine-informed crowds”, [Online]. Erişilebilir: <https://www.pnas.org/doi/10.1073/pnas.2110013119>. [Erişildi: 30 Ekim 2025].
- [6]. Javed M., Zhang Z., Dahri F.H., Laghari A.A., “Real-Time Deepfake Video Detection Using Eye Movement Analysis with a Hybrid Deep Learning Approach”, [Online]. Erişilebilir: <https://www.mdpi.com/2079-9292/13/15/2947>. [Erişildi: 30 Ekim 2025].
- [7]. Zhang Y., Pang Z., Huang S., Wang C., Zhou X., “Unmasking AI-created visual content: a review of generated images and deepfake detection technologies”, [Online]. Erişilebilir: <https://link.springer.com/article/10.1007/s44443-025-00154-8>. [Erişildi: 30 Ekim 2025].

- [8]. Yasrab R., Jiang W., Riaz A., "Fighting Deepfakes Using Body Language Analysis", [Online]. Erişilebilir: https://www.researchgate.net/figure/The-proposed-deepfake-detection-method-The-proposed-method-will-extract-the-frames_fig2_350132198. [Erişildi: 30 Ekim 2025].
- [9]. Intel Corporation, "Trusted Media: Real-time FakeCatcher for Deepfake Detection", [Online]. Erişilebilir: <https://www.intel.com/content/www/us/en/research/trusted-media-deepfake-detection.html>. [Erişildi: 10 Kasım 2025].
- [10]. TIME Dergisi, "Honor On-Device AI Deepfake Detection: The Best Inventions of 2025", [Online]. Erişilebilir: <https://time.com/collections/best-inventions-2025/7318478/honor-on-device-ai-deepfake-detection/>. [Erişildi: 10 Kasım 2025].
- [11]. Dr. Sandeep, Dr. Inderjot, "Detecting AI generated Videos in Python: Fake vs Real (DeepFake Detector)", [Online]. Erişilebilir: <https://www.youtube.com/watch?v=Lxp2U-2MwDM>. [Erişildi: 12 Kasım 2025].
- [12]. Arslan M. E., Güler E., "Deepfake Video Tespiti (Deepfake Video Detection)", [Online]. Erişilebilir: https://www.youtube.com/watch?v=X_4MVQd5ta0. [Erişildi: 12 Kasım 2025].
- [13]. Hatipoğlu A., Arslan O., "Derin Öğrenme İle Deepfake Video Detection Projesi", [Online]. Erişilebilir: <https://www.youtube.com/watch?v=fxwckmfWpD8>. [Erişildi: 12 Kasım 2025].
- [14]. Afchar, D., Nozick, V., Yamagishi, J., Echizen, I., "MesoNet: a Compact Facial Video Forgery Detection Network", IEEE International Workshop on Information Forensics and Security (WIFS), (2018).
- [15]. Ondrej, T., Richard, E., Dinh, N., & Bjoern, A., *DDD_samples.gif* [Görsel]. FaceForensics GitHub deposu. [Online]. Erişilebilir: https://github.com/ondyari/FaceForensics/blob/master/images/DDD_samples.gif. [Erişildi: 15 Kasım 2025].
- [16]. Dlib, "Index of files", [Online]. Erişilebilir: <https://dlib.net/files/> [Erişildi: 30 Aralık 2025].
- [17]. Fabien M., "Xception Architecture Explained", [Online]. Erişilebilir: <https://maelfabien.github.io/deeplearning/xception/#what-does-it-look-like> [Erişildi: 15 Kasım 2025].

